Πολυτεχνείο Κρήτης

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Στατιστική Μοντελοποίηση και Αναγνώριση Προτύπων (ΤΗΛ 311)

1η Σειρά Ασκήσεων

Ομάδα 121

Ονοματεπώνυμα	ΑΜ
Πιερτζοβάνης Νίκος	2016030001
Φώτη Ερμιόνη	2020030081

Ημερομηνία Παράδοσης : 19/05/2024

Θέμα 1: Principal Component Analysis

Σε αυτήν την άσκηση χρησιμοποιήσαμε την μέθοδο Principal Component Analysis (PCA) αρχικά πάνω σε ένα σύνολο δεδομένων που περιγράφουν καλοήθεις και κακοήθεις όγκους στο στήθος και στη συνέχεια χρησιμοποιήσαμε το PCA σε ένα μεγαλύτερο σύνολο δεδομένων 5000 εικόνων προσώπων.

Μέρος 1

Συμπληρώσαμε κατάλληλα τα matlab/octave scripts που μας δόθηκαν έτσι ώστε εκτελώντας το αρχικό script ex1_1_pca.m:

a) Αρχικά διαβάζει το αρχείο 'data/breast_cancer_data.csv' το οποίο περιέχει 569 δείγματα το καθένα εκ των οποίων περιγράφεται με ένα διάνυσμα 30 χαρακτηριστικών. Η τελευταία τιμή στο διάνυσμα είναι η κατηγοριοποίηση του δείγματος σε καλοήθες(0) και κακοήθες(1). Ο κώδικας για το παραπάνω μας έχει δοθεί υλοποιημένος και φαίνεται παρακάτω.

```
%  The following command loads the breast cancert dataset. You should now have the
%  variable X in your environment
Data=csvread('data/breast_cancer_data.csv');
NSamples = 100; %Get the first NSamples only for better visualization
X=Data(1:NSamples,1:end-1); % Get all features
Y=Data(1:NSamples,end);
```

b) Επιλέξαμε ζεύγη χαρακτηριστικών(1,2) και τα απεικονίσαμε στο 2D χώρο. Χρησιμοποιήσαμε διαφορετικό χρώμα για κάθε κατηγορία και παρατηρήσαμε πόσο διαφοροποιούνται οι κλάσεις ανάλογα με τα ζεύγη χαρακτηριστικών.

```
% Visualize the example dataset in 2D using sample feature pairs
% Repeat using different feature pairs on the 2D space
figure(1)
plot(X(Y==0, 1), X(Y==0, 2), 'bo',X(Y==1, 1), X(Y==1, 2), 'ro' );
axis square;
title('Data Samples in 2D')
xlabel('Feature 1');
ylabel('Feature 2');
hold on
```

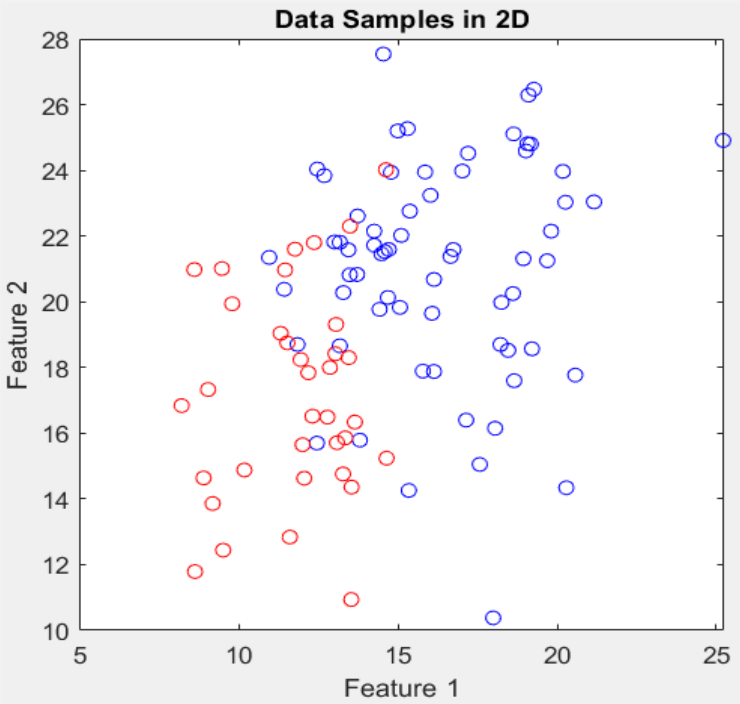

Επαναλάβαμε την διαδικασία για τα ζεύγη χαρακτηριστικών(20,21).

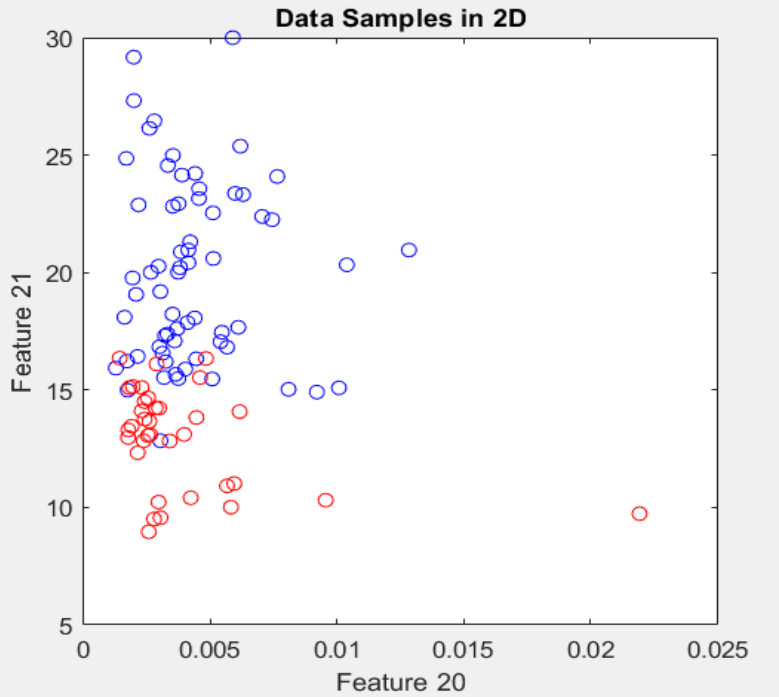

Σε κάθε περίπτωση οι μπλε κύκλοι αντιπροσωπεύουν τα δείγματα που ανήκουν στην κατηγορία 0, ενώ οι κόκκινοι κύκλοι αντιπροσωπεύουν τα δείγματα που ανήκουν στην κατηγορία 1.

c) Εφαρμόσαμε standarization (κανονικοποίηση με μέση τιμή 0 και διασπορά 1) στα αρχικά δείγματα και τα σχεδιάσαμε σε διαφορετική εικόνα ώστε να τα συγκρίνουμε με τα αρχικά.

```
function [X_norm, mu, sigma] = featureNormalize(X)
%FEATURENORMALIZE Normalizes the features in X
%   FEATURENORMALIZE(X) returns a normalized version of X where
%   the mean value of each feature is 0 and the standard deviation
%   is 1. This is often a good preprocessing step to do when
%   working with learning algorithms.


% ADD YOUR CODE
mu = mean(X);
sigma = std(X);
X_norm = (X - mu) ./ sigma;


% ============================================================

end
```

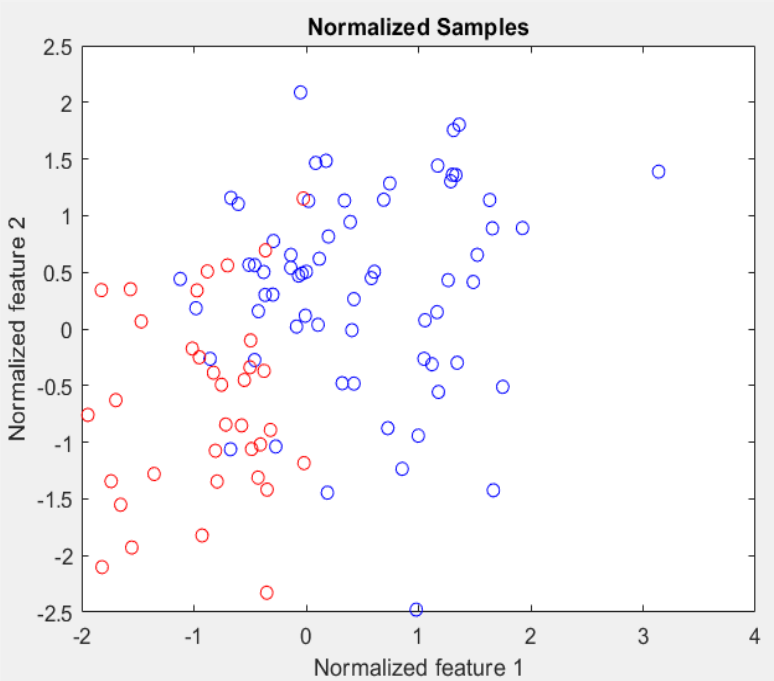

Συγκρίνοντας τα κανονικοποιημένα δείγματα σε σχέση με τα αρχικά παρατηρούμε ότι τα κανονικοποιημένα δείγματα είναι συγκεντρωμένα γύρω από το μηδέν και είναι ομοιόμορφα κατανεμημένα στην περιοχή [-2.5 , 2.5].

b. Υπολογίσαμε τις κύριες συνιστώσες του αλγορίθμου PCA και τις σχεδιάσαμε στην ίδια εικόνα μαζί με τα αρχικά δείγματα, αφού προσθέσαμε πρώτα κώδικα στο αρχείο myPca.m. Για να υπολογίσουμε τον πίνακα συνδιασποράς κανονικοποιημένων δεδομένων χρησιμοποιήσαμε τον τύπο

$\Sigma = \frac{1}{m} * X^T * X$, όπου X Ε R^{m*n}. Για να υπολογίσουμε ιδιοτιμές και ιδιοδιανύσματα χρησιμοποιήσαμε την συνάρτηση Matlab *eig()*.

```
function [ eigenval, eigenvec, order] = myPCA(X)
%PCA Run principal component analysis on the dataset X
%   [ eigenval, eigenvec, order] = mypca(X) computes eigenvectors of the autocorrelation matrix of X
%   Returns the eigenvectors, the eigenvalues (on diagonal) and the order
%

% Useful values
[m, n] = size(X);

% Make sure each feature from the data is zero mean
X_centered = X - mean(X);

% ====================== YOUR CODE HERE ======================
Sigma = (1 / m) * (X_centered' * X_centered);
[eigenvec, D] = eig(Sigma);
eigenval = diag(D); % Vector of Eigenvalues
[eigenval, order] = sort(eigenval,'descend'); %Sorting order
eigenvec = eigenvec(:, order); %Corresponding eigenvector
eigenval = diag(eigenval);
% =========================================================================

end
```

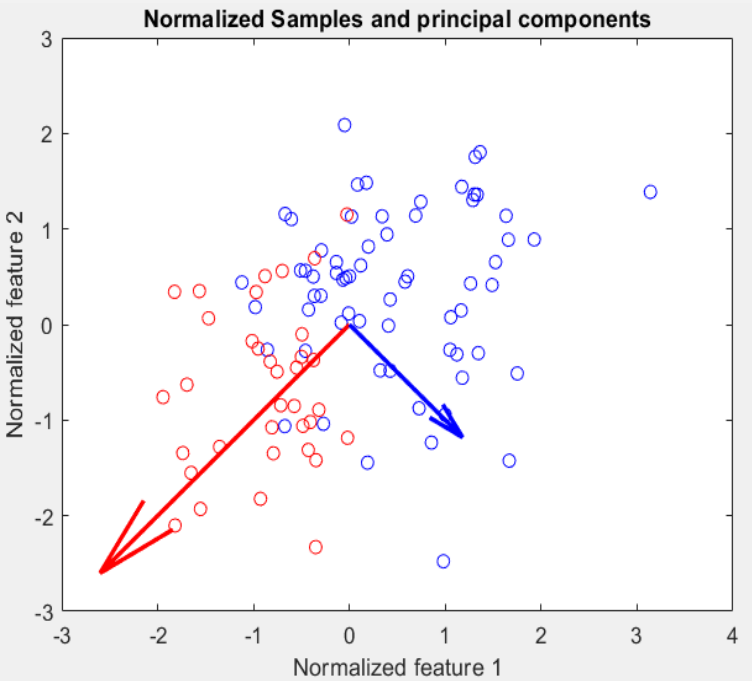

Παρατηρούμε ότι οι κύριες συνιστώσες ξεκινάνε από το σημείο (0,0) και αντιπροσωπεύουν τη διεύθυνση με τη μεγαλύτερη διακύμανση.

c. Υπολογίσαμε τη συνεισφορά που έχει κάθε κύρια συνιστώσα (explained variance) στην συνολική διακύμανση και ακολούθως εφαρμόσαμε τον αλγόριθμο PCA στα δείγματα για να μειώσουμε την διάστασή τους από 2D σε 1D. Συμπληρώσαμε τον κώδικα στο projectData.m έτσι ώστε αυτό να επιστρέφει τα δείγματα Z μειωμένης διάστασης. Η είσοδος του projectData είναι το σύνολο δεδομένων X, οι κύριες συνιστώσες U και ο επιθυμητός αριθμός διαστάσεων K. Προβάλλαμε κάθε δείγμα $\boldsymbol{xi}$ στις K

κύριες συνιστώσες με την εφαρμογή του γραμμικού μετασχηματισμού (προβολή χαμηλότερης διάστασης) $\boldsymbol{zi} = \boldsymbol{U}\ \boldsymbol{Txi}$.

```
function Z = projectData(X, U, K)
%PROJECTDATA Computes the reduced data representation when projecting only
%on to the top k eigenvectors
%   Z = projectData(X, U, K) computes the projection of
%   the normalized inputs X into the reduced dimensional space spanned by
%   the first K columns of U. It returns the projected examples in Z.
%

% You need to return the following variables correctly.
Z = zeros(size(X, 1), K);

% ====================== YOUR CODE HERE ======================
% Instructions: Compute the projection of the data using only the top K
%               eigenvectors
%

Z = X * U(:, 1:K);

% =============================================================

end
```

```
Explained Variance(1st PC = 0.687891) (2nd PC = 0.312109)
1st Principal Component = -0.707107 -0.707107
```

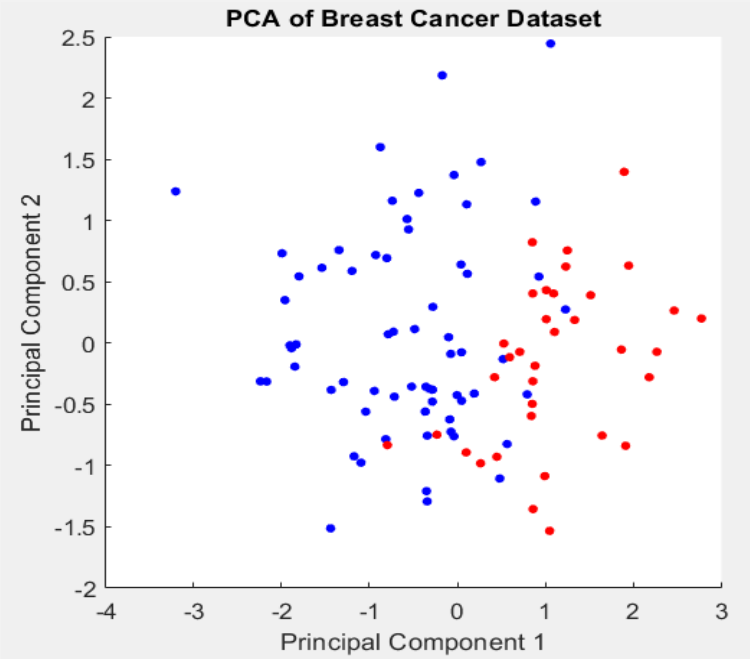

d. Αφού προβάλλαμε τα δεδομένα σε χώρο μικρότερων διαστάσεων, ανακτήσαμε προσεγγιστικά τα δεδομένα αναπαράγοντάς τα ξανά στον αρχικό χώρο υψηλών διαστάσεων (2D). Αυτό γίνεται με την προβολή τους πάνω σε όλες τις κύριες συνιστώσες (principal components) με τον μετασχηματισμό $\boldsymbol{xrec} = \boldsymbol{Uz}$. Υλοποιήσαμε το recoverData.m για να προβάλουμε κάθε δείγμα στο $Z \in \mathbb{R}n \times K$ πίσω στον αρχικό χώρο και να

επιστρέψουμε την ανακτημένη προσέγγιση στον $Xrec \in \mathbb{R}n \times m$ ο οποίος περιέχει τα ανακτημένα δείγματα.

```
function X_rec = recoverData(Z, U, K)
%RECOVERDATA Recovers an approximation of the original data when using the
%projected data
%   X_rec = RECOVERDATA(Z, U, K) recovers an approximation the
%   original data that has been reduced to K dimensions. It returns the
%   approximate reconstruction in X_rec.
%

% You need to return the following variables correctly.
X_rec = zeros(size(Z, 1), size(U, 1));

% ====================== YOUR CODE HERE ======================
% Instructions: Compute the approximation of the data by projecting back
%               onto the original space using the top K eigenvectors in U.
%
%

X_rec = Z * U(:, 1:K)';

% =============================================================

end
```

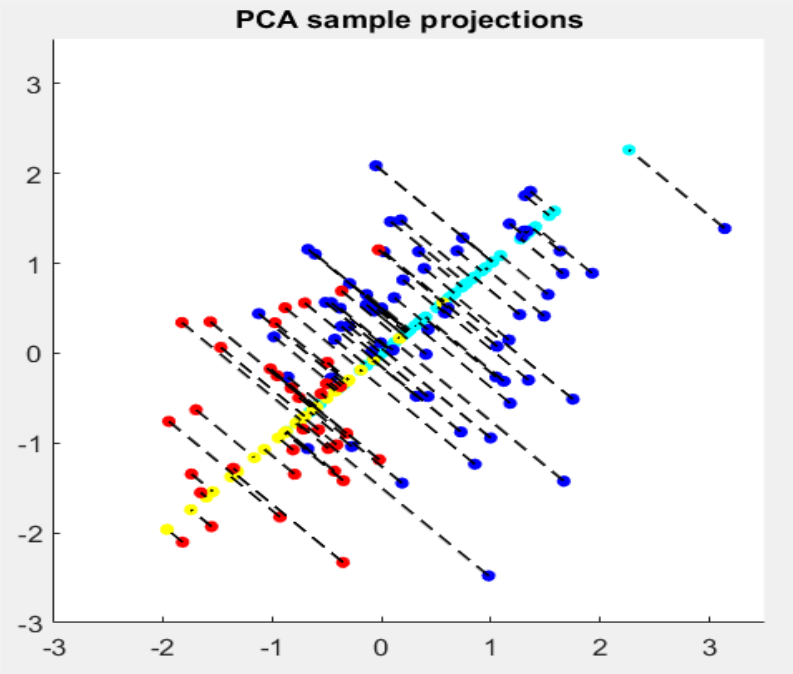


```
Projection of the first example: 1.058683
Approximation of the first example: -0.748602 -0.748602
```

e. Επαναλάβαμε την ανάλυση PCA χρησιμοποιώντας αυτή τη φορά όλο το διάνυσμα χαρακτηριστικών (30 χαρακτηριστικά). Ακολούθως επιλέξαμε τις δύο πρώτες κύριες συνιστώσες και σχεδιάσαμε την προβολή των δειγμάτων σε αυτές.

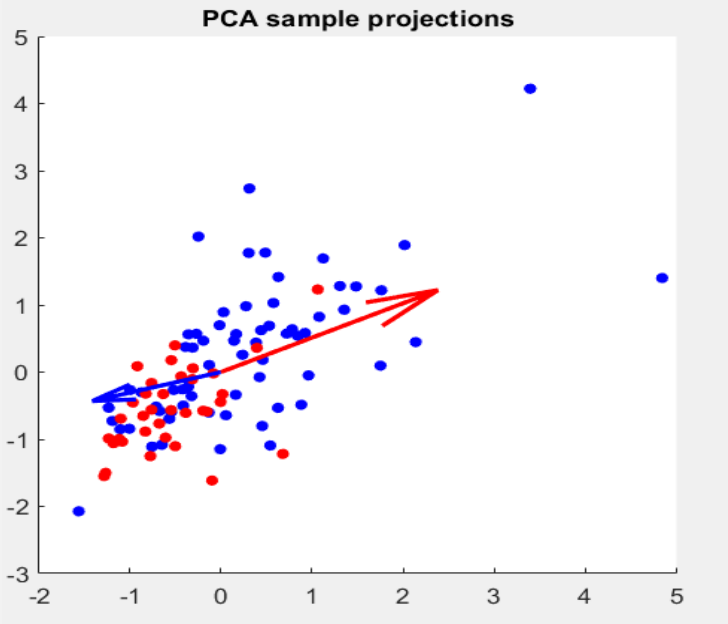

Παρατηρούμε ότι οι κύριες συνιστώσες παρουσιάζουν διαφορετική κατεύθυνση σε σχέση με το βήμα b καθώς πλέον λαμβάνουμε υπόψη όλα τα χαρακτηριστικά των δειγμάτων με αποτελέσματα καθώς μεταβάλλεται η μέση τιμή και η διασπορά των δεδομένων.

Στη συνέχεια, σχεδιάσαμε τις κύριες συνιστώσες στο ίδιο γράφημα με τα χαρακτηριστικά που εμφανίζουν την μεγαλύτερη διακύμανση.

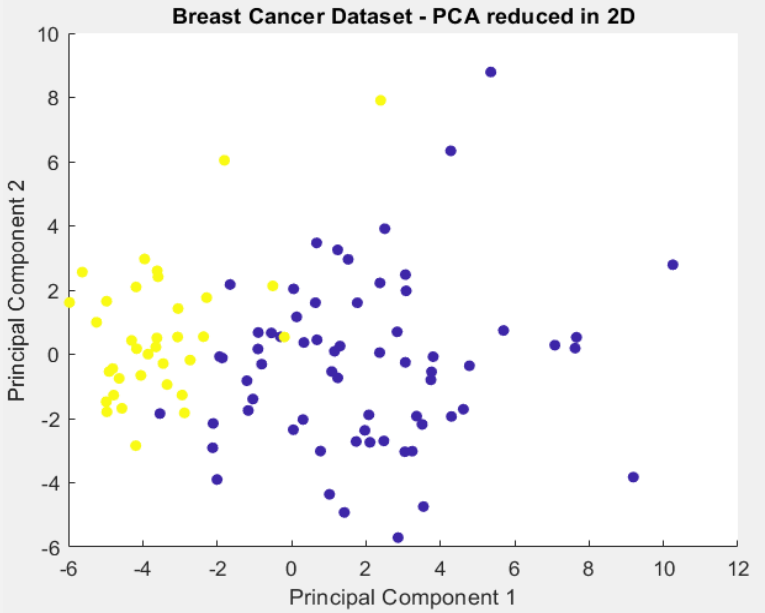

<u>Μέρος 2</u>

Επαναλάβαμε τα παραπάνω χρησιμοποιώντας τα δεδομένα 5000 εικόνων προσώπων που μας δίνονται (load('data\faces.mat')). Συγκεκριμένα χρησιμοποιώντας τον κώδικα που φτιάξατε πιο πάνω υπό την προϋπόθεση ότι μπορεί να εφαρμοστεί σε γενικευμένα dataset:

f. Σχεδιάσαμε τα πρώτα 100 πρόσωπα από το dataset χρησιμοποιώντας τη συνάρτηση displayData() που μας δίνεται.

g. Εφαρμόσαμε standarization εφαρμόζοντας την featureNormalize() πάνω στα δείγματα που έχουμε και ακολούθως υπολογίσαμε τις κύριες συνιστώσες εφαρμόζοντας τη συνάρτηση myPCA().Σχεδιάσαμε σε μια νέα εικόνα τις πρώτες 36 κύριες συνιστώσες που βρήκαμε με την συνάρτηση displayData(). Τι παρατηρείτε;

Παρατηρούμε ότι στην πρώτη περίπτωση οι εικόνες είναι πιο λεπτομερείς και περιέχουν όλες τις πληροφορίες του dataset, ενώ από την άλλη οι κύριες συνιστώσες είναι πιο γενικές καθώς παρουσιάζουν μόνο τα πιο σημαντικά χαρακτηριστικά που περιγράφουν τη μέγιστη διακύμανση στα δεδομένα των προσώπων.

h. Μειώστε την διάσταση των δειγμάτων σας χρησιμοποιώντας τις 100 πρώτες κύριες συνιστώσες με την projectData().

i. Σχεδιάσαμε τα δείγματα μειωμένης διάστασης αφού προηγουμένως τα προβάλαμε στον αρχικό χώρο χρησιμοποιώντας τη συνάρτηση recoverData(). Τι παρατηρείτε;

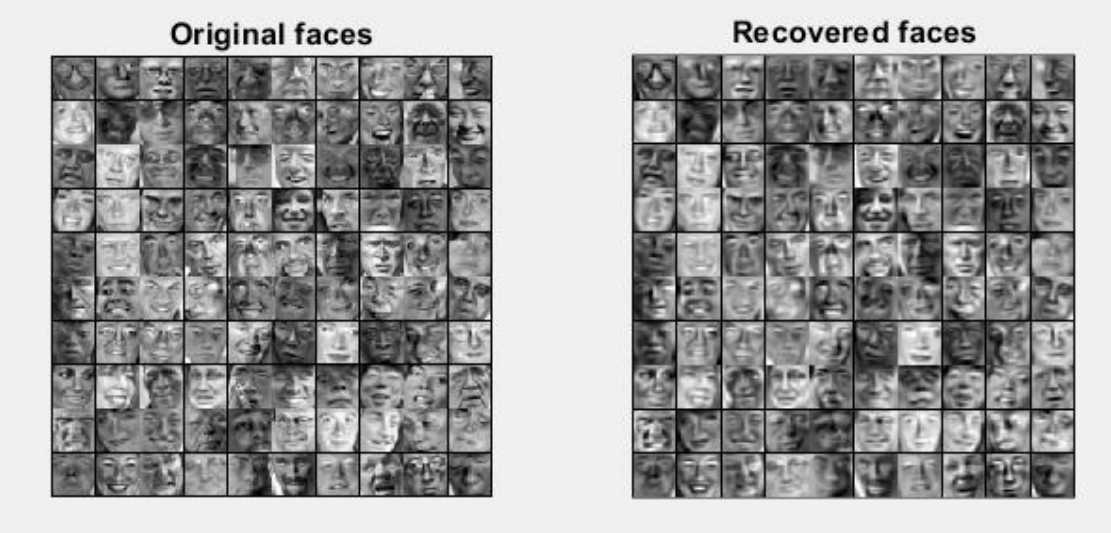

Παρατηρούμε ότι οι ανακατασκευασμένες εικόνες έχουν χάσει κάποιες λεπτομέρειες σε σχέση με τις αρχικές εικόνες. Αυτό συμβαίνει καθώς οι ανακατασκευασμένες εικόνες δεν είναι ακριβείς αντίγραφα των αρχικών εικόνων αλλά μια προσέγγιση αυτών με βάση τις κύριες συνιστώσες.

Επαναλάβαμε την διαδικασία χρησιμοποιώντας διαφορετικό αριθμό από κύριες συνιστώσες (10, 50, 200)

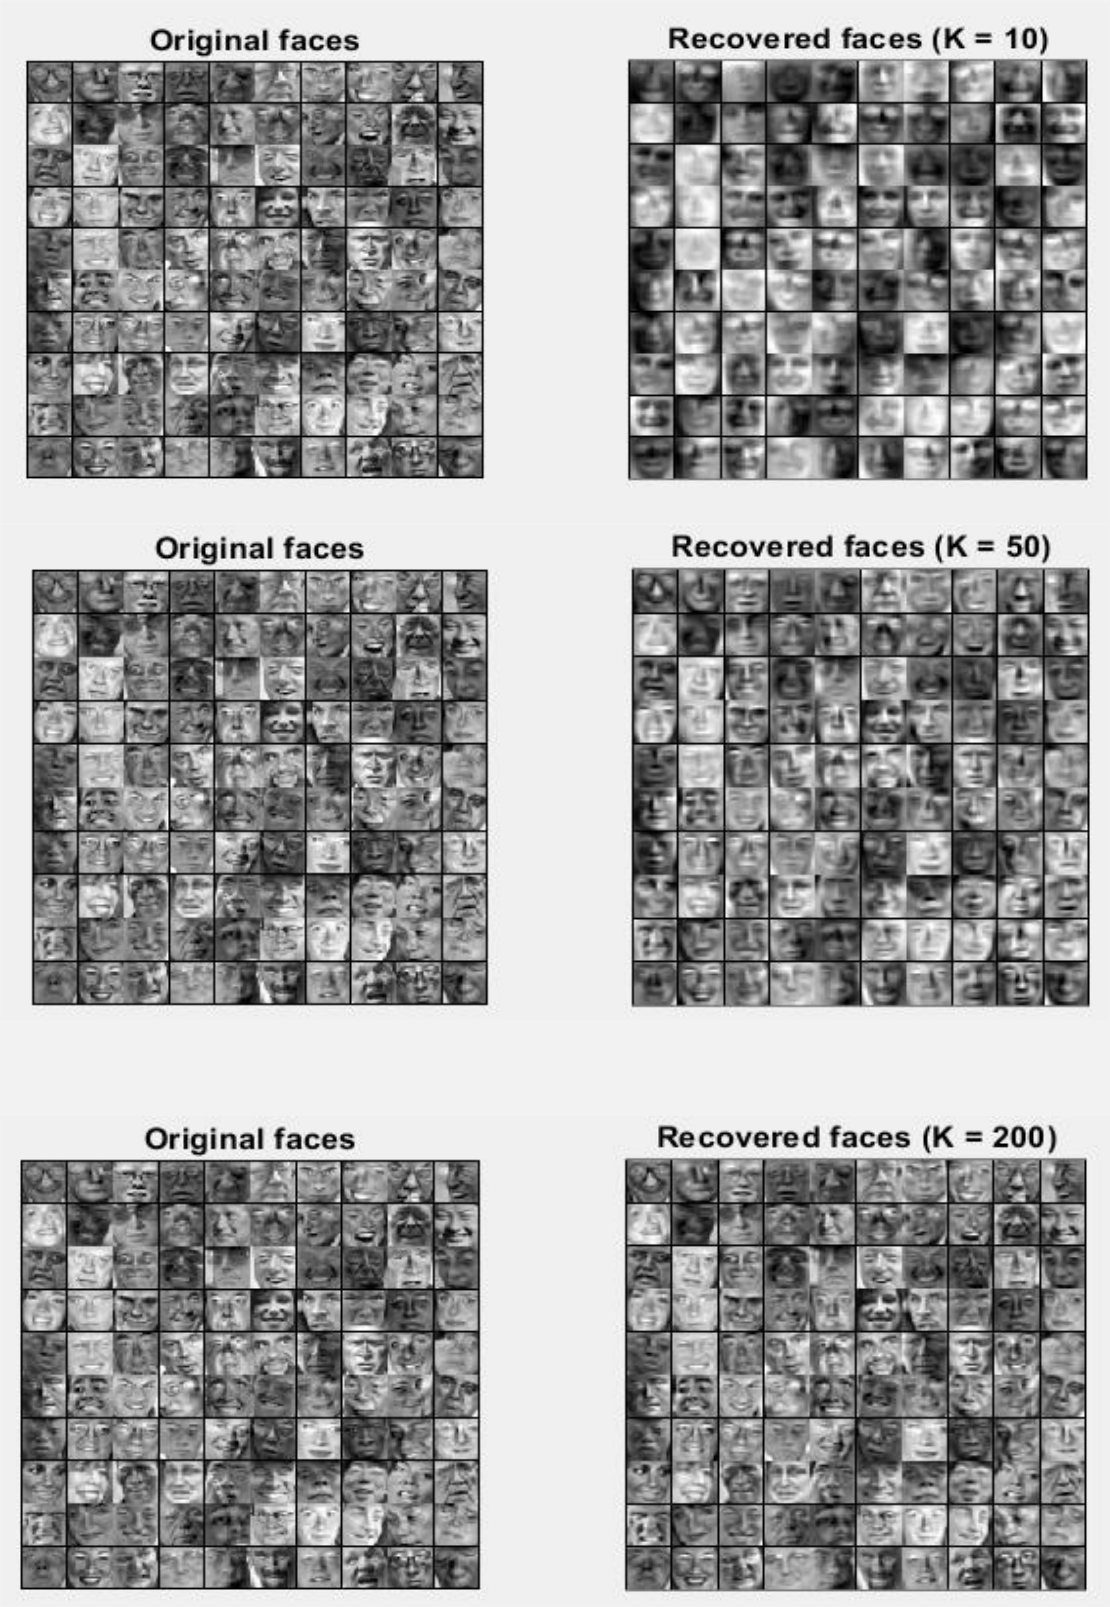

Παρατηρούμε ότι όσο περισσότερες κύριες συνιστώσες χρησιμοποιούνται, τόσο καλύτερη είναι η ποιότητα της

ανακατασκευής των εικόνων. Οι λεπτομέρειες διατηρούνται καλύτερα και οι εικόνες είναι πιο ευκρινείς.

Θέμα 2: Σχεδιάστε ένα ταξινομητή LDA (Linear Discriminant Analysis)

Ένα σύνολο δεδομένων έχει προκύψει από δύο κατηγορίες ωA, ωB , οι κατανομές των οποίων θεωρούνται Γκαουσιανές και η a-Priori πιθανότητα της πρώτης κατηγορίας είναι: $P(\omega_A) = 0.4$. Οι πίνακες συνδιασποράς και οι μέσες τιμές έχουν εκτιμηθεί από τα δεδομένα ως:

$$\mu_A = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \mu_B = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$

$$\Sigma_A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}, \Sigma_B = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

1) Εφαρμόσαμε τη μέθοδο LDA αναλυτικά για να υπολογίσουμε το διάνυσμα προβολής w.

Λύση:

$P(\omega_A) = 0.4 \Rightarrow P(\omega_B) = 1 - P(\omega_A) = 0.6$

Γνωρίζουμε ότι : $S_w = \sum_{i=0}^{c} Pi\Sigma i$

Άρα $S_W = 0.4\Sigma_A + 0{,}6\Sigma_B = 0.4 \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix} + 0{,}6\begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 2.4 & 1 \\ 1 & 2.6 \end{bmatrix}$

Σύμφωνα με τον τύπο $\begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{ad-bc}\begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$ υπολογίσαμε το $(Sw)^{-1}$.

$$(Sw)^{-1} = \frac{1}{5.24}\begin{bmatrix} 2.6 & -1 \\ -1 & 2.4 \end{bmatrix}$$

Για την περίπτωση των δύο κλάσεων το διάνυσμα προβολής w ισούται με:

$$w = (Sw)^{-1}(\mu_A - \mu_B) = \frac{1}{5.24}\begin{bmatrix} 2.6 & -1 \\ -1 & 2.4 \end{bmatrix}\left(\begin{bmatrix} 0 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 0 \end{bmatrix}\right) \Rightarrow$$

$$w = \frac{1}{5.24}\begin{bmatrix} 2.6 & -1 \\ -1 & 2.4 \end{bmatrix}\begin{bmatrix} -2 \\ 2 \end{bmatrix} = \frac{1}{5.24}\begin{bmatrix} -7.2 \\ 6.8 \end{bmatrix} \Rightarrow$$

$$w \simeq \begin{bmatrix} -1.37 \\ 1.30 \end{bmatrix}$$

2) Υπολογίσαμε την προβολή των δύο παρακάτω δειγμάτων, ένα από κάθε κατηγορία, στον άξονα που ορίζεται από το διάνυσμα w:

$$xA = \begin{bmatrix} 1 \\ 3 \end{bmatrix},\ xB = \begin{bmatrix} 3 \\ -1 \end{bmatrix}$$

Λύση:

Η προβολή στον άξονα που ορίζεται από το διάνυσμα w ορίζεται ως:

$$y = \frac{w^T x}{||w||}$$

Επομένως για το x_A έχουμε:

$$y_A = \frac{w^T xA}{||w||} = \frac{1}{\sqrt{(-1.37)^2 + 1.30^2}} \begin{bmatrix} -1.37 & 1.30 \end{bmatrix} \begin{bmatrix} 1 \\ 3 \end{bmatrix} =>$$

$$y_A \simeq 1{,}34$$

Αντίστοιχα για το x_B θα ισχύει:

$$y_B = \frac{w^T xB}{||w||} = \frac{1}{\sqrt{(-1.37)^2 + 1.30^2}} \begin{bmatrix} -1.37 & 1.30 \end{bmatrix} \begin{bmatrix} 3 \\ -1 \end{bmatrix} =>$$

$$y_B \simeq -2.86$$

Θέμα 3: Linear Discriminant Analysis (LDA) vs PCA

Ο σκοπός της άσκησης είναι να εφαρμόσουμε Linear Discriminant Analysis για να μειώσουμε τη διάσταση ενός feature vector και να συγκρίνουμε τα αποτελέσματα μας με τη μέθοδο PCA.

<u>Μέρος 1</u>

a) Αρχικά φορτώσαμε τα δείγματα με την εντολή load('data\data2.mat') και δημιουργήθηκαν οι μεταβλητές c που περιέχει την κλάση και η X που περιέχει τα χαρακτηριστικά διανύσματα.

b) Έπειτα κάναμε standarization (κανονικοποιήση με μ = 0 και σ = 1) χρησιμοποιώντας τη συνάρτηση featureNormalize και σχεδιάσαμε με τα δείγματα της κάθε κλάσης στην ίδια εικόνα.

```
function [X_norm, mu, sigma] = featureNormalize(X)
%FEATURENORMALIZE Normalizes the features in X
%   FEATURENORMALIZE(X) returns a normalized version of X where
%   the mean value of each feature is 0 and the standard deviation
%   is 1. This is often a good preprocessing step to do when
%   working with learning algorithms.


mu = mean(X); % mean of each column (feature)

sigma = std(X); % standart deviation of each column
X_norm = (X - mu) ./ sigma; % normalize each column independently


% ============================================================

end
```

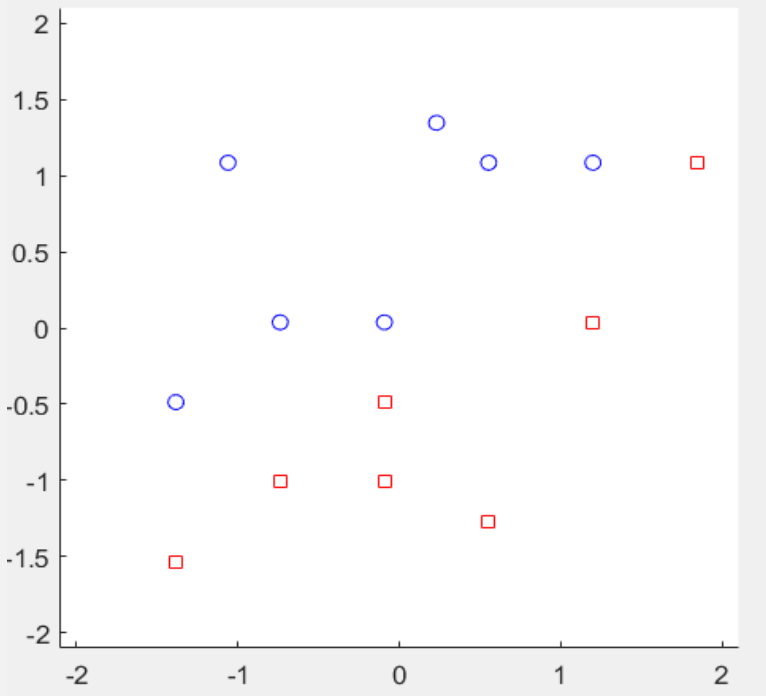

c) Στη συνέχεια προσθέσαμε τον απαραίτητο κώδικα στο αρχείο «fisherLinearDiscriminant.m» έτσι ώστε αυτό να υλοποιεί τον αλγόριθμο LDA για προβλήματα 2 κλάσεων.

```
function v = fisherLinearDiscriminant(X1, X2)

    m1 = size(X1, 1);
    m2 = size(X2, 1);

    mu1 = mean(X1); % mean value of X1
    mu2 = mean(X2); % mean value of X2

    S1 = cov(X1); % scatter matrix of X1
    S2 = cov(X2); % scatter matrix of X2

    Sw = (S1 + S2) / 2; % Within class scatter matrix

    v = inv(Sw) * (mu1 - mu2)'; % optimal direction for maximum class separation

    v = v / norm(v); % return a vector of unit norm
```

d) Προσθέσαμε τον κατάλληλο κώδικα στο αρχείο «projectDataLDA.m» ώστε τρέχοντας τη συνάρτηση να δημιουργούνται δείγματα μειωμένης διάσταση (1D).

```
function [Z] = projectDataLDA(X, v)

% You need to return the following variables correctly.
Z = zeros(size(X, 1), 1);

% ====================== YOUR CODE HERE ======================

Z = X * v;

% ============================================================

end
```

e) Προσθέσαμε τον κατάλληλο κώδικα στο αρχείο «recoverDataLDA.m» ώστε να κάνουμε ανακατασκευή των δειγμάτων μειωμένης διάστασης στον 2D χώρο προβάλλοντας τα πάνω στην κατεύθυνση του διανύσματος προβολής LDA.

```
function [X_rec] = recoverDataLDA(Z, v)

% You need to return the following variables correctly.
X_rec = zeros(size(Z, 1), length(v));

% ====================== YOUR CODE HERE ======================

X_rec = Z*v';

% ============================================================

end
```

Σχεδιάσαμε πάνω στην ίδια εικόνα τα δείγματα μειωμένης διάστασης όπως προβάλλονται στον 2D χώρο μαζί με τα αρχικά μας δείγματα.

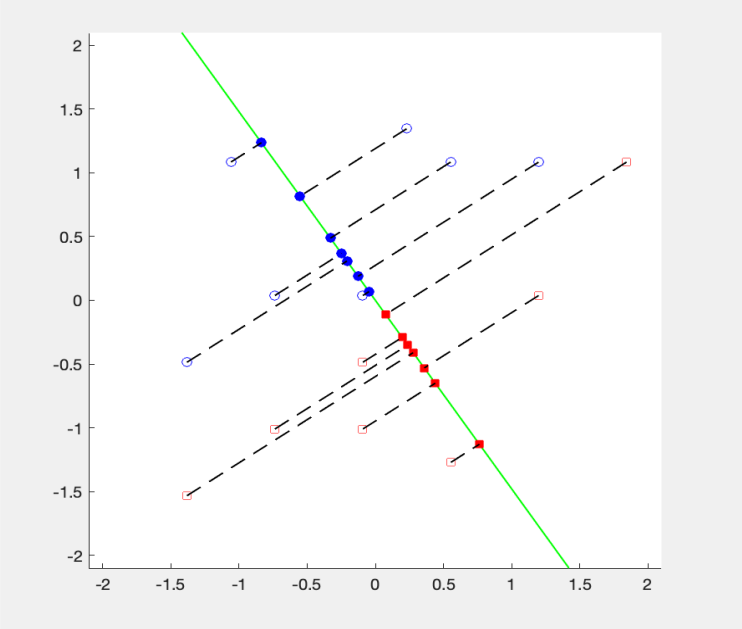

f) Τέλος, εφαρμόσαμε την αντίστοιχη διαδικασία μείωσης διάστασης με τη μέθοδο PCA όπως την εφαρμόσαμε και στο θέμα 1 και σχεδιάσαμε τα δείγματα που προκύπτουν με τη μέθοδο PCA.

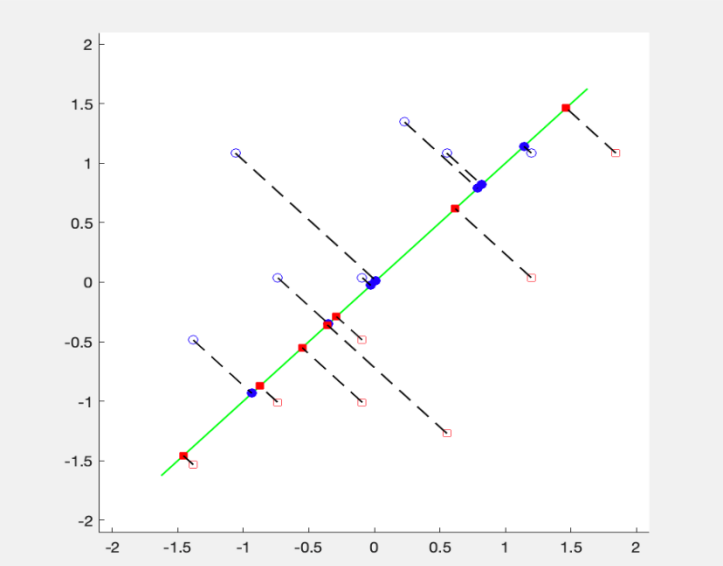

Συγκρίνοντας τα δείγματα που προκύπτουν με τη μέθοδο PCA με αυτά που προκύπτουν με την μέθοδο LDA παρατηρούμε ότι με την μέθοδο LDA επιτυγχάνουμε εμφανή διαχωρισμό των κλάσεων ενώ με την μέθοδο PCA έχουμε επικάλυψη των δύο κλάσεων με αποτέλεσμα να μην είναι δυνατός ο διαχωρισμός των δύο κλάσεων.

<u>Μέρος 2</u>

Σ' αυτό το μέρος εφαρμόσαμε τον αλγόριθμο LDA στη βάση δεδομένων Fisher's Iris, η οποία περιέχει 50 δείγματα από 3 διαφορετικά είδη της οικογένειας του λουλουδιού του είδους Iris. Κάθε δείγμα αποτελείται από

τέσσερα χαρακτηριστικά/μετρήσεις των λουλουδιών και συγκεκριμένα το μήκος και το πλάτος (σε cm) των σέπαλων και των ανθόφυλλων.

a) Φορτώσαμε τα δείγματα iris ως εξής: load('fisheriris.mat'). Με την παραπάνω εντολή θα δημιουργηθεί η μεταβλητή $\boldsymbol{meas}$ που περιέχει τα 150 δείγματα (χαρακτηριστικά διανύσματα) και η μεταβλητή $\boldsymbol{species}$ που περιέχει την κλάση για κάθε δείγμα (είναι σε μορφή cell).

b) Εφαρμόσαμε standarization στα δείγματα και ακολούθως σχεδιάσαμε τα 2 πρώτα χαρακτηριστικά (features) σε ένα 2D γράφημα χρησιμοποιώντας ξεχωριστά χρώματα για κάθε κλάση.

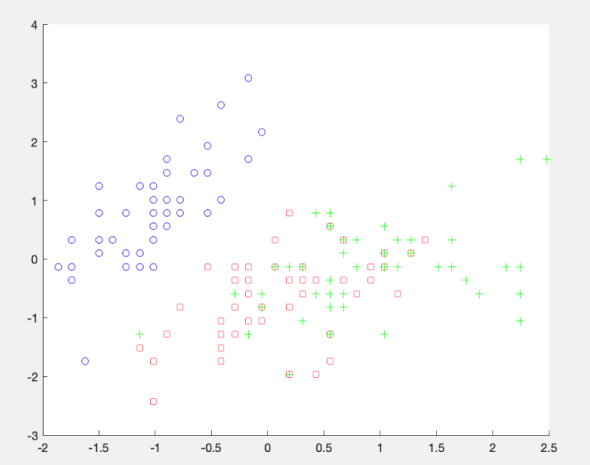

c) Προσθέσαμε τον απαραίτητο κώδικα στη συνάρτηση myLDA η οποία δέχεται στην είσοδο τα κανονικοποιημένα δείγματα, τα labels της κλάσης στην οποία ανήκουν και τον αριθμό των διαστάσεων ($\boldsymbol{NewDim}$) στις οποίες θέλουμε να μειώσουμε το χώρο των χαρακτηριστικών. Επιλέξαμε τη νέα διάσταση του διανύσματος των χαρακτηριστικών να είναι $\boldsymbol{NewDim}$=2. Αυτό που επιστρέφει είναι ένας πίνακας που να περιέχει στις στήλες του τα διανύσματα προβολής LDA. Για να υλοποιήσουμε τη συνάρτηση υπολογίσαμε από τα δεδομένα εισόδου:

1. Τις prior πιθανότητες των Κλάσεων
2. Τις μέσες τιμές των Κλάσεων
3. Τον ολικό μέσο
4. Τον πίνακα σκέδασης $\boldsymbol{S_W}$ (Within-Class Scatter Matrix)
5. Τον πίνακα σκέδασης $\boldsymbol{S_b}$ (Between-Class Scatter Matrix)
6. Τον πίνακα $\boldsymbol{S^{-1}S}$ του γενικευμένου συστήματος ιδιοτιμών στον οποίο θα πρέπει να $\boldsymbol{wb}$

και εφαρμόσαμε eigendecomposition. Δηλαδη΄υπολογίσαμε ιδιοτιμές και ιδιοδιανύσματα, τα ταξινομήσαμε με φθίνουσα σειρα΄ιδιοτιμής και κρατήσαμε τα ιδιοδιανύσματα που αντιστοιχούν στις μεγαλύτερες $NewDim$ = 2 ιδιοτιμές.

```
%For each class i
%Find the necessary statistics

for i = 1:NumClasses
Xi = Samples(Labels == Classes(i), :); % Samples of class i
Ni = size(Xi, 1); % Number of samples in class i

%Calculate the Class Prior Probability
P(i)= Ni / NumSamples;
%Calculate the Class Mean
mu(i,:)= mean(Xi);
%Calculate the Within Class Scatter Matrix
Si = cov(Xi);
Sw= Sw + Si * P(i);%(Ni - 1);
%Calculate the Global Mean
m0 = mean(Samples); % Global Mean


%Calculate the Between Class Scatter Matrix
meanDiff = mu(i, :) - m0;
Sb= Sb + P(i) * (meanDiff * meanDiff');
end

%Eigen matrix EigMat=inv(Sw)*Sb
EigMat = inv(Sw)*Sb;

%Perform Eigendecomposition
[U, S] = svd(EigMat);


%Select the NewDim eigenvectors corresponding to the top NewDim
%eigenvalues (Assuming they are NewDim<=NumClasses-1)
%% You need to return the following variable correctly.
A=zeros(NumFeatures,NewDim); % Return the LDA projection vectors
A = U(:, 1:NewDim);
```

d) Στο τέλος εφαρμόσαμε τα διανύσματα προβολής που υπολογίσαμε με την myLDA πάνω στα αρχικά σας δείγματα με τη συνάρτηση projectDataLDA για να μειώσουμε τη διάσταση του σε 2. Τα σχεδιάσαμε σε ένα γράφημα στο επίπεδο (2D) χρησιμοποιώντας ξεχωριστά χρώματα για τις διαφορετικές κλάσεις.

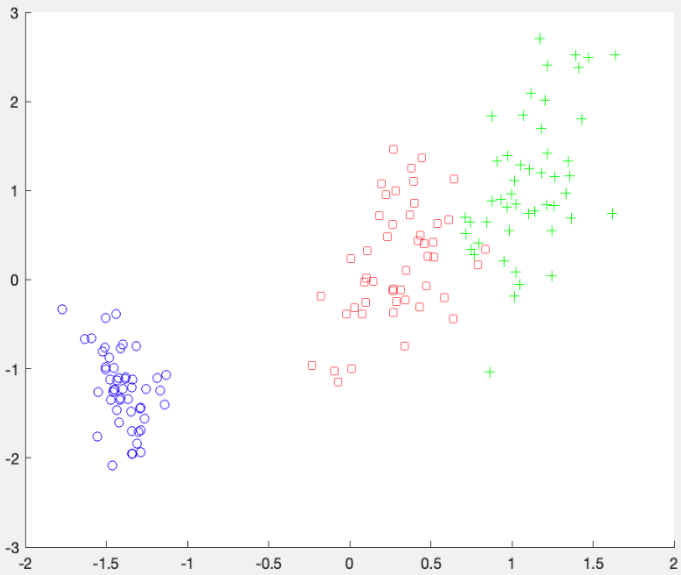

Θέμα 4: Bayes

Έστω ότι σε ένα πρόβλημα κατηγοριοποίησης σε δύο κλάσεις $\omega 1$ και $\omega 2$ οι εκ των προτέρων πιθανότητες είναι $P(\omega 1)$ και $P(\omega 2)$ αντίστοιχα. Τα δείγματα $\boldsymbol{x}$ που πρέπει να κατηγοριοποιηθούν είναι δισδιάστατα (2D) και οι κλάσεις περιγράφονται από τις ακόλουθες κανονικές κατανομές:

$$P(x|\omega_1) = N(\mu_1,\Sigma_1)\ ,\ P(x|\omega_2) = N(\mu_2,\Sigma_2)$$

Όπου

$$\mu_1 = \begin{pmatrix} 2 \\ 3 \end{pmatrix} \quad \Sigma_1 = \begin{pmatrix} 2 & 0.5 \\ 0.5 & 1 \end{pmatrix}$$

$$\mu_2 = \begin{pmatrix} 4 \\ 4 \end{pmatrix} \quad \Sigma_2 = \begin{pmatrix} 1.5 & -0.3 \\ -0.3 & 0.8 \end{pmatrix}$$

1) Υπολογίσαμε την συνάρτηση του συνόρου απόφασης(Decision Boundary).

Για τον υπολογισμό της συνάρτησης του συνόρου απόφασης αρχικά υπολογίσαμε τους αντίστροφους των πινάκων συνδιασποράς:

$$\Sigma 1^{-1} = \frac{1}{2-0.25}\begin{pmatrix} 1 & -0.5 \\ -0.5 & 2 \end{pmatrix} = \begin{pmatrix} 0.571 & -0.286 \\ -0.286 & 1.143 \end{pmatrix}$$

$$\Sigma 2^{-1} = \frac{1}{1.2-0.09}\begin{pmatrix} 0.8 & 0.3 \\ 0.3 & 1.5 \end{pmatrix} = \begin{pmatrix} 0.721 & 0.270 \\ 0.270 & 1.351 \end{pmatrix}$$

Στην συνέχεια, υπολογίσαμε τις ορίζουσες των πινάκων συνδιασποράς:

$|\Sigma_1| = 1*2 - (-0.5)*(-0.5) = 1.75$
$|\Sigma_2| = 0.8*1.5 - 0.3*0.3 = 1.11$

Υπολογίσαμε το σύνορο διαχωρισμού εξισώνοντας τις συναρτήσεις διαχωρισμού.

$$g_1(x) = -\frac{1}{2}(x-\mu 1)^T \Sigma 1^{-1}(x-\mu 1) + \ln\big(P(\omega 1)\big) - \ln(2\pi) - \frac{1}{2}\ln|\Sigma 1|$$

$$g_2(x) = -\frac{1}{2}(x-\mu 2)^T \Sigma 2^{-1}(x-\mu 2) + \ln\big(P(\omega 2)\big) - \ln(2\pi) - \frac{1}{2}\ln|\Sigma 2|$$

$$g_1(x) = g_2(x) \Rightarrow$$

$$-\frac{1}{2}(x-\mu 1)^T \Sigma 1^{-1}(x-\mu 1) + \ln\big(P(\omega 1)\big) - \ln(2\pi) - \frac{1}{2}\ln|\Sigma 1| =$$

$$-\frac{1}{2}(x-\mu 2)^T \Sigma 2^{-1}(x-\mu 2) + \ln\big(P(\omega 2)\big) - \ln(2\pi) - \frac{1}{2}\ln|\Sigma 2| \Rightarrow$$

$$(x-\mu 1)^T \Sigma 1^{-1}(x-\mu 1) - (x-\mu 2)^T \Sigma 2^{-1}(x-\mu 2) =$$

$$2\ln\big(P(\omega 1)\big) - 2\ln\big(P(\omega 2)\big) - \ln|\Sigma 1| + \ln|\Sigma 2| \Rightarrow$$

$$-\frac{1}{2}(x-\mu 2)^T \Sigma 2^{-1}(x-\mu 2) + \ln\big(P(\omega 2)\big) - \ln(2\pi) - \frac{1}{2}\ln|\Sigma 2| =$$

$$\ln\left(\frac{P(\omega 1)}{P(\omega 2)}\right) + \ln\left(\frac{|\Sigma 2|}{|\Sigma 1|}\right)$$

Λύνοντας την εξίσωση υπολογίζεται το σύνορο απόφασης(Decision Boundary).

2) Χρησιμοποιήσαμε Python για να σχεδιάσουμε τις ισοϋψείς καμπύλες των δύο κατανομών $p(x|\omega_i)$ Ε R^2

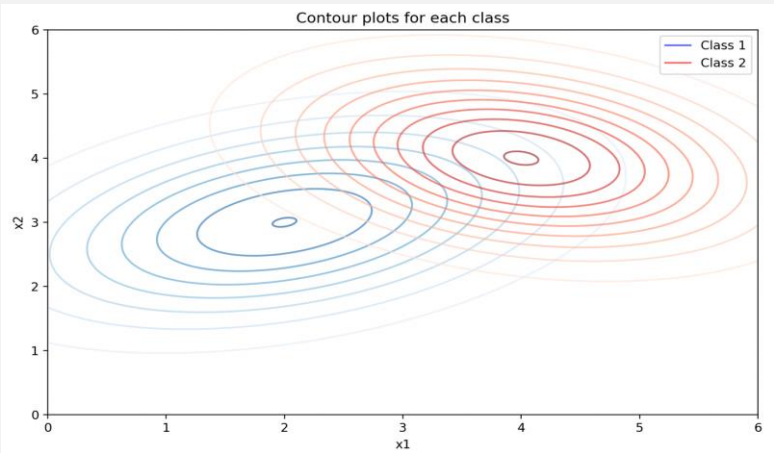

3) Δεδομένου ότι $P(\omega 2) = 1 - P(\omega 1)$, σχεδιάσαμε στην ίδια εικόνα τα σύνορα απόφασης για τις ακόλουθες τιμές της εκ των προτέρων πιθανότητας $P(\omega 1) = 0.1, 0.25, 0.5, 0.75, 0.9$.

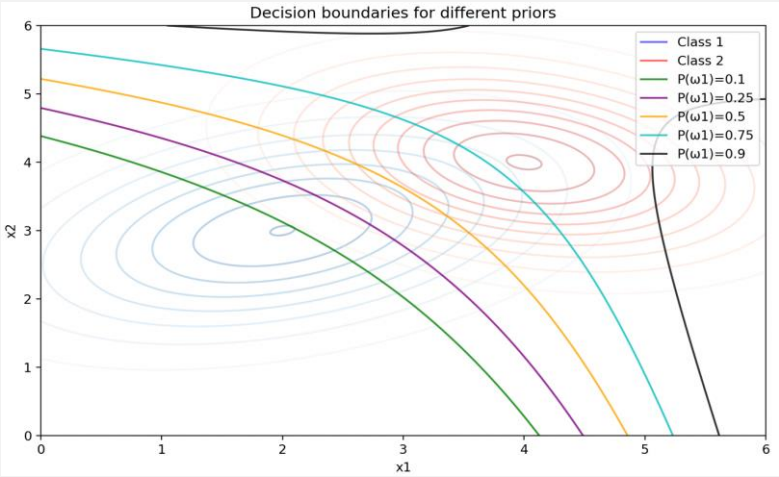

Οι γραμμές απόφασης είναι μη γραμμικές καμπύλες. Αυτό συμβαίνει επειδή οι κατανομές έχουν διαφορετικές μέσες τιμές και συνδιακυμάνσεις.

Παρατηρούμε ότι όταν η εκ των προτέρων πιθανότητα $P(\omega_1)$ είναι μικρή το σύνορο απόφασης μετατοπίζεται πιο κοντά στην κλάση 1. Αυτό μας δείχνει ότι περισσότερα στοιχεία είναι πιο πιθανό να ανήκουν στην κλάση 2 εκ των προτέρων. Αντίστοιχα, όταν η εκ των προτέρων πιθανότητα $P(\omega_1)$ είναι μεγάλη το σύνορο απόφασης μετατοπίζεται πιο κοντά στην κλάση 2. Αυτό μας δείχνει ότι περισσότερα στοιχεία είναι πιο πιθανό να ανήκουν στην κλάση 1 εκ των προτέρων. Στην περίπτωση που οι εκ των προτέρων πιθανότητες είναι ίσες, δηλαδή $P(\omega_1) = P(\omega_2) = 1/2$ το σύνορο απόφασης βρίσκεται στο μέσον των δύο κλάσσεων.

4) Επαναλάβαμε τις παραπάνω ερωτήσεις υποθέτοντας ότι οι πίνακες συνδιασποράς είναι ίδιοι:

$$\Sigma_1 = \Sigma_2 = \begin{pmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{pmatrix}$$

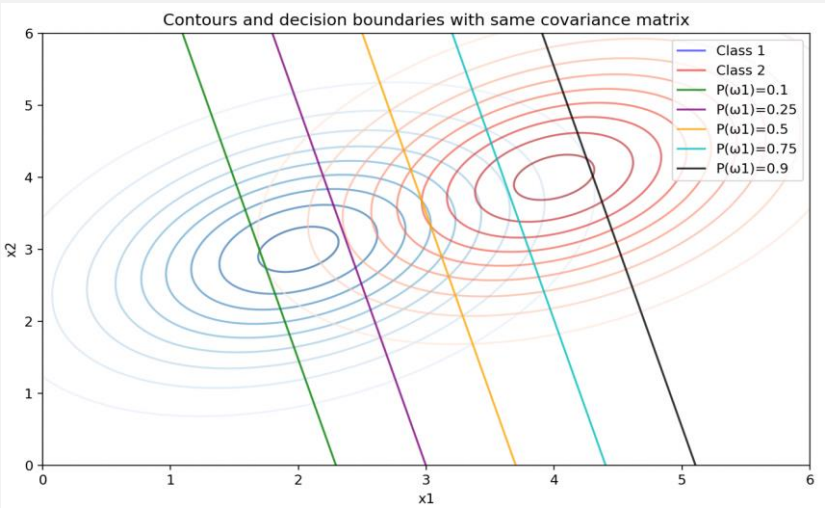

Όταν οι δύο κλάσσεις έχουν τον ίδιο πίνακα συνδιασποράς, οι ισοϋψείς καμπύλες παρουσιάζουν ίδια διασπορά και η μόνη διαφορά τους είναι η μέση τιμή.
Τα σύνορα απόφασης των δύο κλάσσεων είναι πλέον γραμμικά.
Οι μετατοπίσεις των συνόρων απόφασης αλλάζουν με τον ίδιο τρόπο όπως προηγουμένως σύμφωνα με τις τιμές των εκ των προτέρων πιθανοτήτων.

Θέμα 5: Εξαγωγή χαρακτηριστικών και Bayes Classification

Στον κατάλογο exercise1_5/data υπάρχουν τα αρχεία mnist_train.csv και το mnist_test.csv τα οποία περιέχουν χειρόγραφες εικόνες των αριθμητικών ψηφίων [0,1,2,3,4,5,6,7,8,9] χωρισμένες σε δείγματα εκπαίδευσης το πρώτο και δείγματα ελέγχου το δεύτερο (mnist_test.csv). Σε αυτή την άσκηση προσπαθήσαμε να δημιουργήσουμε έναν απλό ταξινομητή Bayes ο οποίος θα μπορεί να ταξινομεί δείγματα σε δύο κλάσεις και συγκεκριμένα στις κλάσεις $C1$ και $C2$των ψηφίων 1 και 2 αντίστοιχα. Συνεπώς αγνοήσαμε αρχικά τα υπόλοιπα δείγματα. Για να κάνουμε ταξινόμηση χρειάστηκε να δημιουργήσουμε χαρακτηριστικά για κάθε δείγμα εικόνας.

<u>Μέρος 1</u>

a) Υπολογίσαμε τον λόγο όψεως (aspect ratio) όπως ορίζεται πιο πάνω για κάθε εικόνα που ανήκει στις κλάσεις $C1$ και $C2$ στο train και testset. Συμπληρώσαμε τον κώδικα που λείπει στη συνάρτηση aspect_ratio.

b) Σχεδιάσαμε δύο οποιαδήποτε δείγματα από το dataset (ένα από κάθε κλάση) μαζί με ένα παραλληλόγραμμο (bounding box) στα όρια του aspect ratio που υπολογίσαμε (όπως στις παραπάνω εικόνες) για να βεβαιωθούμε ότι υπολογίζεται σωστά.

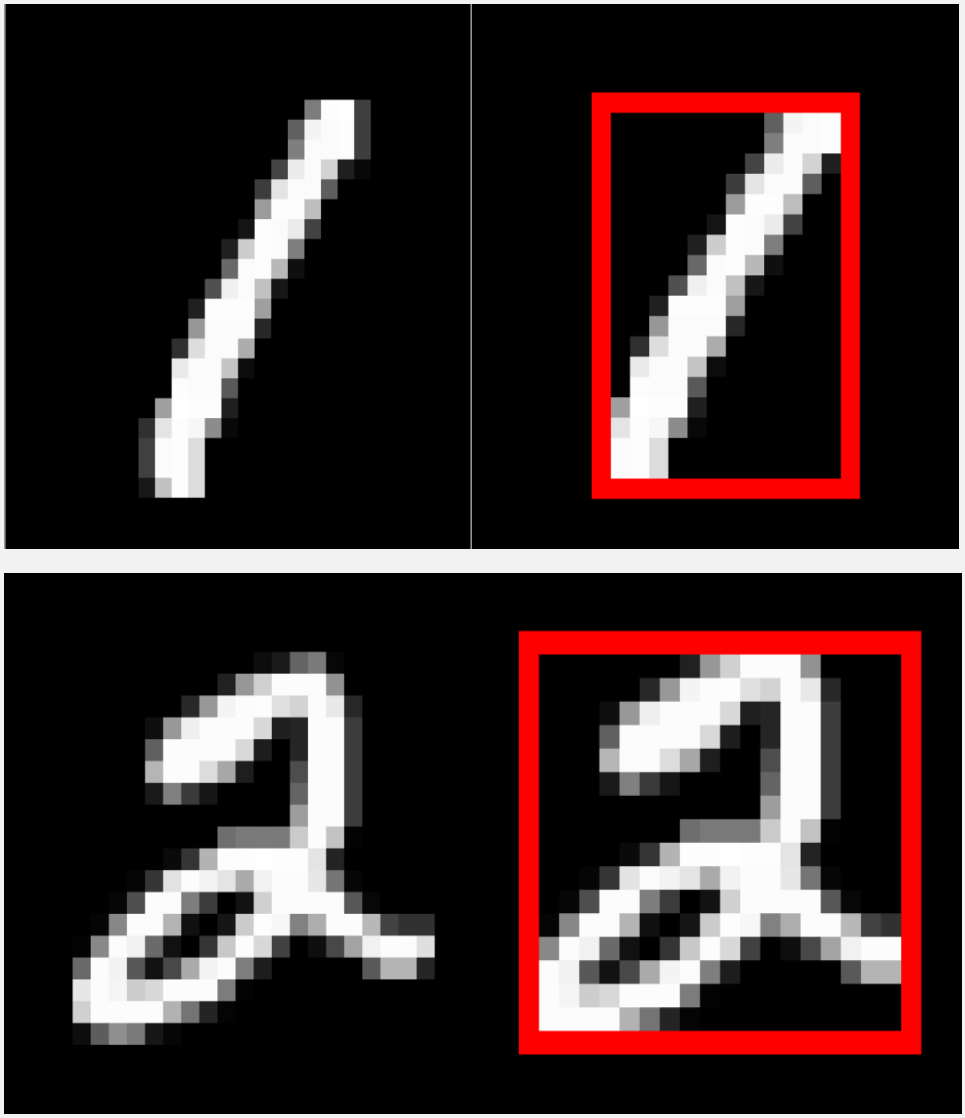

Παρατηρούμε ότι το aspect ratio υπολογίζει σωστά το ελάχιστο ορθογώνιο που περικλείει ένα ψηφίο.

c) Πριν χρησιμοποιήσουμε το χαρακτηριστικό, εφαρμόσαμε min-max κανονικοποίηση στο aspect ratio στο διάστημα [-1, 1] συμπληρώνοντας κατάλληλα τη συνάρτηση min_max_scaling.

d) Υπολογίσαμε από τα δείγματα τις εκ των προτέρων πιθανότητες $P(C1)$ και $P(C2)$ συμπληρώνοντας κατάλληλα τον κώδικα στη μέθοδο train της κλάσης "MyBayesClassifier".

e) Έστω ότι η κατανομή του aspect ratio χαρακτηριστικού σε κάθε κλάση ακολουθεί κανονική κατανομή με μέση τιμή

$\overline{\mu} = \frac{1}{N}\sum_{i=1}^{N} xi$ και τυπική απόκλιση $\sigma = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(xi - \overline{\mu})^2}$, όπου xi τα δείγματα εκπαίδευσης της κλάσης των εικόνων. Εκπαιδεύσαμε έναν Bayes ταξινομητή στη μέθοδο train.

f) Βρήκαμε ποια είναι η πρόβλεψη της κλάσης στα δείγματα ελέγχου χρησιμοποιώντας τον ταξινομητή που εκπαιδεύσατε (predict).

g) Εκτιμήσαμε την ακρίβεια ταξινόμησης στο σύνολο των δειγμάτων ελέγχου (test) και σχολιάσαμε το αποτέλεσμα.

```
Classification accuracy: 0.9545454545454546
```

Παρατηρούμε ότι όταν έχουμε να ταξινομήσουμε δύο διαφορετικά δείγματα σε κλάσεις, το 1 και το 2, χρησιμοποιώντας μόνο το aspect ratio ως χαρακτηριστικό διαχωρισμού η ακρίβεια του διαχωρισμού είναι αρκετά υψηλή.

h) Προσθέσαμε ως νέο χαρακτηριστικό τον αριθμό των μη μαύρων pixels που σχηματίζουν τον αριθμό σε κάθε εικόνα (foreground_pixels). Επαναλάβαμε την διαδικασία εκπαίδευσης του Bayes ταξινομητή κάνοντας την υπόθεση ότι τα χαρακτηριστικά είναι ανεξάρτητα μεταξύ τους.

```
Classification accuracy: 0.9628099173553719
```

Η πρόσθεση του χαρακτηριστικού των pixels που σχηματίζουν τον κάθε αριθμό αυξάνει την ακρίβεια του σωστού διαχωρισμού.

i) Προσθέσαμε ως τρίτο χαρακτηριστικό την τιμή του κεντροειδούς (κέντρο μάζας των μη μηδενικών pixels). Το κεντροειδές ορίζεται ως συντεταγμένες στο επίπεδο της εικόνας. Για να το μετασχηματίσουμε σε μονοδιάστατο χαρακτηριστικό κάναμε τον μετασχηματισμό ($centroid = centX + (centY * W)$), όπου W είναι το πλάτος της εικόνας, και centX, centY οι συντεταγμένες του κεντροειδούς που υπολογίσατε. Επαναλάβαμε την διαδικασία εκπαίδευσης του Bayes ταξινομητή χρησιμοποιώντας όλα τα χαρακτηριστικά μαζί και κάνοντας την υπόθεση ότι τα χαρακτηριστικά είναι ανεξάρτητα μεταξύ τους.

```
Classification accuracy: 0.9669421487603306
```

Η πρόσθεση του κεντροειδούς ως τρίτο χαρακτηριστικό διαχωρισμού αυξάνει ακόμα περισσότερο την ακρίβεια.

j) Επαναλάβαμε τα παραπάνω θεωρώντας ότι έχουμε τρεις κλάσεις και συγκεκριμένα τα ψηφία 0, 1, 2. Πως μεταβάλλεται η ακρίβεια του ταξινομητή σ' αυτή την περίπτωση;

```
Classification accuracy: 0.7155963302752294
Classification accuracy: 0.7155963302752294
```

```
Classification accuracy: 0.7155963302752294
```

Σε αυτήν την περίπτωση διαχωρίζοντας τρεις διαφορετικούς αριθμούς σε τρεις κλάσεις η ακρίβεια σωστού διαχωρισμού μειώνεται έντονα. Παρ'όλα αυτά ενώ θα περιμέναμε προσθέτοντας χαρακτηριστικά για την ταξινόμηση η ακρίβεια του διαχωρισμού να αυξάνεται παρατηρούμε ότι παραμένει σταθερή.

Θέμα 6: Minimum Risk

Έστω ότι σε ένα πρόβλημα κατηγοριοποίησης σε δύο κλάσεις $\omega 1$ και $\omega 2$ οι εκ των προτέρων πιθανότητες είναι ίσες $P(\omega 1) = P(\omega 2)$. Τα δείγματα $\boldsymbol{x}$ που πρέπει να κατηγοριοποιηθούν είναι μονοδιάστατα (1D) και ακολουθούν κατανομή Rayleigh με συνάρτηση πυκνότητας πιθανότητας που δίνεται από την ακόλουθη σχέση:

$$p(x|\omega_i) = \frac{x}{\sigma i^2} e^{-\frac{x^2}{2\sigma i^2}}, \; x \geq 0 \quad \text{και } 0, \; x < 0$$

Με $\sigma 1 = 1$ και $\sigma 2 = 2$. Υπολογίσαμε το όριο απόφασης $\boldsymbol{x}0$ που έχει το μικρότερο ρίσκο, δεδομένου ότι ο πίνακας ρίσκου είναι:

$$\mathrm{L} = \begin{bmatrix} 0 & 0.5 \\ 1.0 & 0 \end{bmatrix}$$

Λύση:

Με βάση το κριτήριο ελαχιστοποίησης του μέσου ρίσκου έχουμε:

$$l1 \;=\; L11\, p(\omega 1)\, p(x|\omega 1) \;+\; L21\, p(\omega 2)\, p(x|\omega 2)$$

$$l2 \;=\; L12\, p(\omega 1)\, p(x|\omega 1) \;+\; L22\, p(\omega 2)\, p(x|\omega 2)$$

Για να βρούμε το όριο απόφασης x_o :

$$l1 \;=\; l2 \;=>$$

$$L21\, p(\omega 2)\, p(x|\omega 2) \;=\; L12\, p(\omega 1)\, p(x|\omega 1) \;=> (\sigma_1 = 1, \sigma_2 = 2)$$

$$1\frac{x}{4} e^{-\frac{x^2}{8}} = \frac{1}{2}\frac{x}{1} e^{-\frac{x^2}{2}} =>$$

$$\ln\left(\frac{1}{2}e^{-\frac{x^2}{8}}\right) = \ln\left(\ e^{-\frac{x^2}{2}}\right) =>$$

$$\ln(2) - \frac{x^2}{8} = -\frac{x^2}{2} =>$$

$$x = 2\sqrt{\frac{2\ln(2)}{3}} \text{ ή } x = -2\sqrt{\frac{2\ln(2)}{3}}$$

Αφού όμως έχουμε σαν δεδομένο ότι $p(x|\omega_i) = 0$ για $\chi < 0$, το όριο απόφασης ισούται με :

$$x0 = 2\sqrt{\frac{2\ln(2)}{3}} => x0 \simeq 1.359$$